

Речевая аналитика: двухуровневая архитектура как бизнес-модель

«Извлечение — у себя, интеллект — по подключению» ·
версия 2 от 11 июля 2026 · внутренний рабочий документ

Спутник основного документа «Модуль речевой аналитики поверх RingAI» (техническое видение). Здесь — развёрнутая бизнес-модель: что клиент получает навсегда и независимо, что — по подключению, как это продаётся и как устроено хранение данных.

1. Суть одним абзацем

Клиент покупает **базовый продукт, который навсегда работает у него** — на обычном сервере с одной розничной видеокартой, без счётчиков минут, без зависимости от нас и от интернета. Он получает расшифровку 100% звонков, контроль скриптов, эмоции, темы обращений, **базовую оценку операторов** и дашборды. А **«расширенный интеллект»** — глубокую оценку операторов по смыслу, автоматические выводы, самообучение бота — клиент **подключает** как услугу: к общему серверу своей компании, к нашему сервису по подписке или к арендованной на ночь машине. Метафора: базовый продукт — автомобиль в собственности; подключаемый интеллект — штурман, которого можно нанять, сменить или уволить; машина остаётся вашей и едет.

Почему так можно у нас и почти ни у кого больше: самая тяжёлая часть любой речевой аналитики — распознавание речи — в нашем стеке работает **на обычном процессоре**. Серьёзная GPU-инфраструктура нужна ровно одному компоненту — большой языковой модели. Поэтому граница «своё / подключаемое» проходит не по маркетинговому решению, а по естественному техническому шву.

2. Уровень 1: что у клиента работает ВСЕГДА и НЕЗАВИСИМО

Комплектация базового уровня: **обычный сервер + одна розничная видеокарта (класс RTX 4090, 24 ГБ)** — по умолчанию считаем, что она у заказчика есть; это единственное требование к железу.

Формулировка для переговоров: **«даже если завтра отключат интернет, а послезавтра закончится подписка — вот что продолжит работать у вас как ни в чём не бывало»:**

1. **Расшифровка 100% звонков.** Каждый звонок превращается в текст на вашем сервере (обычный процессор, видеокарта не занята). Поиск по всем разговорам: «найди звонки, где обещали перезвонить».
2. **Контроль скриптов и запрещённых фраз (комплаенс).** Поздоровался ли оператор, представился ли, назвал ли обязательные условия, не сказал ли запрещённого — по настраиваемым словарям, на каждом звонке, объяснимо и воспроизводимо.

3. **3. Объективные метрики разговора.** Перебивал ли оператор, сколько молчал, какую долю разговора говорил, темп речи.
4. **4. Эмоции по голосу.** С каким настроением клиент пришёл и с каким ушёл, где точка эскалации — фильтр «покажи 20 самых конфликтных звонков за вчера».
5. **5. Темы обращений и новые темы.** О чём звонят, что растёт, что всплыло впервые — карточки тем с примерами.
6. **6. Базовая оценка операторов** (подробно — §4): автоматический скоринг каждого оператора по слоям 1–3 (скрипт, поведение в разговоре, эмоции, простые смысловые проверки) + выявление проблемных операторов и проблемных звонков.
7. **7. Дашборды, отчёты, выгрузки, уведомления** по всему перечисленному.
8. **8. Малая языковая модель на вашей видеокарте.** Работает на той самой одной розничной карте из комплектации: краткое резюме каждого звонка, автоматические названия новых тем, простые смысловые проверки для базового скоринга («назвал ли оператор итоговую сумму» — да/нет). Полностью у вас, без внешних подключений.

И принципиальное: **хранение данных — только у вас** (устройство — §7). Аудио, тексты, оценки не покидают ваш контур в базовой комплектации никогда.

3. Уровень 2: что добавляет подключение

Подключаемый интеллект — большая языковая модель (класс 32+ млрд параметров), которой нужна серьёзная видеокарта. Что она добавляет:

1. **1. Расширенную оценку операторов** (подробно — §4): полный смысловый чек-лист с цитатами-обоснованиями, диагностику причин и рекомендации коучу.
2. **2. Автоматические выводы:** еженедельный дайджест «пять главных болей клиентов, динамика, вероятные причины» — для руководства, не для КЦ.
3. **3. Самообучение бота** (флагман): новая тема из аналитики → черновик нового навыка бота, собранный из лучших ответов операторов → ревью → бот умеет. Уровень автоматизации растёт от каждого месяца работы.
4. **4. Развёрнутые резюме сложных звонков, «плейбук лучших операторов», прогноз оттока.**

Как выглядит разница на одной карточке звонка:

Поле карточки
Текст разговора
Скрипт соблюден (по пунктам)
Перебивания, паузы, доля речи
Эмоции: пришёл/ушёл, точка эскалации
Простые смысловые проверки (да/нет)
Краткое резюме звонка
Тема звонка

Полный смысловой чек-лист с цитатами
Развёрнутое резюме сложного звонка
Рекомендация коучу

Важное свойство: поля «ожидает обработки» **дозаполняются** при подключении уровня 2 — задним числом, по всей накопленной истории. Клиент ничего не теряет, откладывая подключение: копится очередь, а не пропасть.

4. Оценка операторов: базовая — у вас, расширенная — по подключению

Ключевое разделение модели. **Базовая аналитика по операторам живёт на уровне 1 и независима всегда**; уровень 2 добавляет глубину, а не включает оценку как таковую.

Базовый скоринг (уровень 1) отвечает на вопросы «у кого проблема и где»:

- " Г соблюдение скрипта: приветствие, представление, обязательные и запрещённые фразы — по каждому звонку;
- " Г поведение в разговоре: перебивания, паузы, доля речи, темп;
- " Г эмоциональная динамика: как часто клиенты уходят от оператора злее, чем пришли; точки эскалации;
- " Г простые смысловые проверки малой моделью: бинарные, по коротким фрагментам («назвал ли сумму», «попрощался ли»);
- " Г сводный балл оператора из этих слоёв, рейтинг команды, динамика по неделям, автоматическое выявление аномалий («у Марии с прошлого вторника резко выросли эскалации»).

Расширенный скоринг (уровень 2) отвечает на вопросы «почему и что делать»:

- " Г полный смысловой чек-лист: «выявил ли потребность», «работал ли с возражением», «предложил ли решение», «подтвердил ли, что вопрос решён» — каждый ответ с цитатой из разговора;
- " Г диагностика паттерна: не разовые ошибки, а систематика («в звонках с возражением о цене не предлагает рассрочку — 14 из 17 случаев»);
- " Г рекомендация коучу с примерами звонков и таймкодами;
- " Г сравнение с «плейбуком лучших»: что делают топ-операторы в таких же ситуациях, чего не делает этот.

Пример на одном операторе — как это выглядит в продукте:

Вопрос руководителя КЦ
У кого из операторов проблемы?
Где именно проблемы?
Почему?
Что делать?

Формула для продаж: **базовый уровень — детектор (находит проблему и показывает где), расширенный — диагност (объясняет почему и назначает лечение)**. Детектор у клиента навсегда; диагност — по подключению.

5. Три формы подключения уровня 2 — под три типа клиентов

Форма А. Общий сервер внутри компании — для крупных (телеком, банк). Каждый контакт-центр/филиал держит дешёвый узел уровня 1; один GPU-сервер уровня 2 обслуживает всех. Данные не покидают периметр компании вообще. *Пример: А1 — узлы в КЦ, один сервер в ЦОДе компании; для банка это единственная приемлемая форма по комплаенсу.*

Форма Б. Наш сервис по подписке — для среднего бизнеса (медцентры, ритейл, сервисные сети). Узел уровня 1 отправляет на наш сервис **обезличенные тексты** (фамилии, номера, адреса вырезаются автоматически ещё на стороне клиента — до отправки) и получает обратно оценки и выводы. Аудио не передаётся никогда. *Пример: сеть из трёх медцентров — сервер уровня 1, подписка на интеллект помесечно; конверсию «звонок → запись» считает базовый уровень, а «почему администратор Мария теряет записи на вечерние слоты» отвечает подписка.*

Форма В. Арендованная машина под ночную обработку — для тех, кто не хочет ни серьёзного своего GPU, ни чужого сервиса. Ночью в облаке (под управлением клиента, его ключи) поднимается машина на 1–2 часа, пережёвывает дневную очередь и гасится. Дневной объём в 10 000 звонков обрабатывается за 1–2 часа одной картой — аренда стоит единицы долларов за ночь. *Пример: ритейл-сеть с пиками в распродажи — платит за часы обработки, а не за простаивающее железо.*

Формы совместимы и переключаемы: начать с Б (быстрый старт), вырасти в А (свой сервер) — контракт между уровнями один и тот же, миграция — переключение адреса.

6. Бизнес-модель: пакеты и логика цены

Пакет

База

Интеллект

Интеллект-контур

Логика, которую легко объяснить клиенту:

- " Г **за независимость платят один раз** (база — ваша навсегда, включая базовую оценку операторов);
- " Г **за глубину платят пока она нужна** — и её можно выключить, не потеряв продукт и накопленные данные;
- " Г **обезличенные тексты — не персональные данные**: подписка (форма Б) юридически легче, чем кажется службе безопасности на первом слушании;

- " Г **очередь вместо потери:** не подключил интеллект в этом месяце — карточки дозаполняются, когда подключишь.

Для нас: база даёт разовую выручку и установку продукта в контур (= удержание), подписка — регулярную выручку, «Интеллект-контур» — крупные чеки enterprise. Продукт растёт вместе с клиентом: медцентр начинает с «Базы», через год покупает подписку, сеть медцентров через два — свой GPU-сервер.

7. Хранение данных: три слоя на стороне заказчика

Все данные аналитики живут **у заказчика** (уровень 1). Три слоя — и для каждого явно: **что хранится, что рассчитывается, за счёт чего и когда обновляется.**

Слой А — сырьё (неизменяемое)

Что хранится
Что рассчитывается
За счёт чего
Когда обновляется
Retention

Слой В — обогащение (по каждому звонку и каждой реплике)

Что хранится
Что рассчитывается
За счёт чего
Когда обновляется

Слой С — витрины (агрегаты)

Что хранится
Что рассчитывается
За счёт чего
Когда обновляется

Что и как уходит на уровень 2 (и только это)

Конверты двух видов, оба собираются уровнем 1:

1. **По-звонковые** (расширенный скоринг, развёрнутое резюме): обезличенный текст **одного** звонка из слоя В + чек-лист → вердикт возвращается и оседает в слое В, агрегаты слоя С обновляются.
2. **Агрегатные** (дайджесты, выводы): цифры из слоя С + отобранные обезличенные примеры-цитаты из слоя В → готовый дайджест.

Аудио не уезжает никогда; ПДн вырезаются до отправки; **всё возвращённое оседает в слоях заказчика — накопленный интеллект остаётся у клиента, даже если подписка закончится.**

Рассмотренные альтернативы (и почему не они)

- " Г *Классический ночной пересчёт всего хранилища* — проще в разработке, но дашборды отстают на сутки, теряется сценарий «алерт по всплеску темы в течение дня». Отвергнут в пользу инкрементального обновления.
- " Г *Полностью потоковая архитектура (Kafka + ClickHouse) с первого дня* — красиво, но избыточно для старта и утяжеляет базовый уровень, который должен ставиться «на обычный сервер». Оставлена как миграционный путь для очень больших инсталляций: слой С переезжает в ClickHouse, конвейер — на очередь; слои A/B и контракт конвертов не меняются.

8. Честные оговорки

1. **1. Подсказки оператору в реальном времени** (высший ярус зрелости) в схему с внешним интеллектом не помещаются — им нужна модель рядом (форма А). Продаём честно: realtime — только со своим GPU-сервером.
2. **2. Форма Б требует доверия к обезличиванию** — вырезатель ПДн должен быть безупречен и проверяем (у клиента есть режим аудита: что именно ушло в конверте).
3. **3. Качество расширенного скоринга подтверждается пилотом** (совпадение с оценками супервизоров $\geq 85\text{--}90\%$) — до этого продаём измеримость, не магию.